

1. 문제 정의와 사용 목적


심장질환은 조기 발견 여부에 따라 환자의 예후가 크게 달라질 수 있는 대표적인 질환이다. 본 프로젝트의 목표는 환자의 임상 데이터로부터 심장병 발병 가능성을 예측하여 심장질환 위험 여부를 예측하는 머신러닝 모델을 구축하는 것이다.

본 시스템은 의사의 진단을 대체하기 위한 목적이 아니라, 환자의 위험도를 사전에 탐지하여 의료진의 의사결정을 지원하는 보조 도구로 사용되는 것을 목표로 한다. 즉, 모델은 최종 진단을 내리는 것이 아니라 추가 검사나 전문의 진료가 필요한 환자를 선별하는 역할을 수행한다.

따라서 본 프로젝트는 심장 전문의의 의사결정을 보조하는 도구이며, 절대 단독으로 결정하는 시스템이 아니다.


2. EDA 핵심 결과

데이터셋은 총 303개의 환자 데이터를 포함하고 있으며, 13개의 입력 특성과 1개의 타깃 변수로 구성되어 있다. 타깃 변수는 0(정상)과 1(심장질환)로 이진 분류 문제로 변환하여 사용하였다.




`value_counts(normalize=True)`로 타깃 클래스 분포를 확인한 결과 정상 환자는 약 54%, 심

장질환 환자는 약 46%로 나타났다. 클래스 불균형이 극단적이지는 않았지만 완전히 동일한 비율도 아니므로 Accuracy만으로 모델을 평가할 경우 특정 클래스에 편향된 해석이 발생할 수 있다. 따라서 본 프로젝트에서는 Accuracy 대신 Balanced Accuracy를 주요 지표로 사용하였으며, 특히 실제 심장병 환자를 놓치는 False Negative를 줄이기 위해 Precision, Recall, F1-score를 함께 평가하였다.



결측값 분석 결과 'ca' 변수에서 4개, 'thal' 변수에서 2개의 결측값이 발견되었으며 전체 결측값 수는 6개였다. 전체 데이터 수가 많지 않기 때문에 결측치를 포함한 행을 삭제할 경우 데이터 손실이 발생할 수 있다고 판단하였다.



연속형 변수(age, trestbps, chol, thalach, oldpeak)에 대해 Boxplot과 IQR 기반 이상치 탐지를 수행하였다. 그 결과 chol, trestbps, oldpeak 등 일부 변수에서 이상치가 확인되었다. 다만 해당 값들은 실제 임상 환경에서도 발생 가능한 수치이므로 단순 삭제보다는 이상치 영향을 완화하는 방향으로 전처리를 수행하는 것이 적절하다고 판단하였다.

EDA 결과를 통해 데이터의 클래스 분포, 결측치 위치, 이상치 존재 여부를 파악할 수 있었으며, 이는 이후 전처리 및 모델 평가 전략을 결정하는 근거로 활용되었다.

3. EDA 결과에 근거한 전처리 결정

EDA 결과를 통해 데이터의 클래스 분포, 결측치, 이상치 및 변수 분포를 확인하였다. 타깃 클래스는 완전히 균형 잡혀 있지 않았기 때문에 단순 Accuracy 대신 Balanced Accuracy, Precision, Recall, F1 Score를 주요 평가 지표로 사용하였다.

결측치 분석 결과 일부 변수에서 결측값이 발견되었으며, 데이터 수가 많지 않은 의료 데이터의 특성을 고려하여 행 삭제 대신 중앙값 대체를 선택하였다. 중앙값은 평균보다 이상치의 영향을 덜 받으므로 의료 데이터에 적합하다고 판단하였다.

연속형 변수(age, trestbps, chol, thalach, oldpeak)의 분포와 boxplot을 통해 이상치를 확인하였다. 다만 의료 데이터의 이상치는 실제 고위험 환자의 특성을 반영할 수 있으므로 단순 제거하지 않고 유지하였다.

데이터는 `train_test_split(test_size=0.2, random_state=42)`을 사용하여 분할하였다. 전체 데이터의 80%를 학습에, 20%를 평가에 사용하였으며, `random_state`를 고정하여 실험 재현성을 확보하였다.

4. MLflow 실험 기반 모델 비교 및 최종 모델 선택

총 3개의 서로 다른 계열의 모델(Logistic Regression, SVC, Random Forest)을 학습하고 비교하였다. 모든 실험 결과는 MLflow를 통해 파라미터, 평가 지표, 모델 아티팩트 및 모델 태그와 함께 기록하였다.

또한 5-Fold 교차 검증을 수행하여 모델의 일반화 성능을 평가하였으며, 가장 우수한 후보 모델에 대해서는 GridSearch 기반 하이퍼파라미터 탐색을 수행하였다. 최종적으로 Random Forest 모델이 가장 우수한 Balanced Accuracy를 기록하여 최종 모델로 선정하였다.

심장질환 예측 문제에서는 실제 환자를 정상으로 분류하는 False Negative가 매우 위험하다. False Negative는 환자가 적절한 검사나 치료 시기를 놓치게 만들 수 있기 때문이다. 따라서 본 프로젝트에서는 단순 Accuracy보다 Recall과 Balanced Accuracy를 중요하게 고려하였으며, Random Forest 모델이 해당 지표에서 가장 안정적인 성능을 보여 최종 모델로 선택하였다.

본 모델은 심장질환을 진단하는 시스템이 아니라 환자의 위험도를 예측하여 의료진에게 참고 정보를 제공하는 의사결정 지원 시스템(inform, not decide)으로 활용되어야 한다.

5. 테스트 및 패키징

파이프라인의 신뢰성을 확보하기 위해 총 4개의 unittest를 작성하였다. 예측 결과의 shape 검증, 예측 확률 범위 검증, 임상적으로 허용 가능한 입력 범위 검증, 동일 입력에 대한 결정론적 출력 검증을 수행하였다. 이러한 테스트는 모델의 기능적 오류와 데이터 품질 문제를 사전에 탐지하기 위한 목적을 가진다.

또한 Docker를 사용하여 실행 환경을 컨테이너화하였다. requirements.txt를 기반으로 의존성을 설치하고, 학습된 모델과 소스 코드를 포함한 이미지를 생성하였다. 이를 통해 환경이 달라지더라도 동일한 추론 결과를 재현할 수 있도록 하였다.

피처 스토어에는 chol(혈중 콜레스테롤 수치)을 저장하는 것이 적절하다고 판단하였다. 해당 변수는 심장질환 위험도와 직접적인 관련이 있으며 학습, 추론, 모니터링 과정에서 일관되게 활용되는 핵심 특성이기 때문이다.

모델 레지스트리에는 모델 버전(version)을 기록해야 한다고 판단하였다. 모델 버전 정보는 특정 예측 결과가 어떤 모델에 의해 생성되었는지 추적할 수 있게 해주며, 성능 저하나 드립트 발생 시 이전 모델로의 롤백과 비교 분석을 가능하게 한다.

6. 드립트 결과 및 재학습 / 피드백 루프 계획

모니터링 단계에서는 테스트 데이터의 chol과 oldpeak 변수에 인위적인 분포 이동을 적용하여 데이터 드리프트 상황을 시뮬레이션하였다. KS-Test 수행 결과 chol($p=5.24 \times 10^{-12}$)과 oldpeak($p=2.81 \times 10^{-6}$)에서 p-value가 0.05보다 작게 나타나 유의미한 데이터 드리프트가 탐지되었다.

또한 원본 데이터에서의 Balanced Accuracy는 0.901이었으나 드리프트 데이터에서는 0.871로 감소하였다. 이는 입력 데이터 분포 변화가 모델 성능 저하로 이어질 수 있음을 보여주며, 실제 운영 환경에서 지속적인 모니터링이 필요함을 시사한다.

본 프로젝트에서는 특정 특성의 드리프트가 지속적으로 탐지되거나 Balanced Accuracy가 사전에 정의한 임계값 이하로 감소할 경우 재학습을 수행하는 전략을 고려하였다. 다만 모델이 자신의 예측 결과를 다시 학습 데이터로 사용하는 자동 재학습 구조는 잘못된 예측이 반복적으로 강화되는 폭주하는 피드백 루프(runaway feedback loop)를 유발할 수 있다.

이를 방지하기 위해 Human-in-the-loop 방식을 적용한다. 즉, 모델 재학습 전에 의료진 또는 데이터 관리자가 새로운 데이터와 라벨의 품질을 검토하고 승인한 이후에만 학습 데이터에 반영하도록 한다. 최종 진단 및 재학습 데이터 승인 과정에는 반드시 사람이 개입하여 모델이 스스로 오류를 증폭시키는 상황을 방지한다.

7. 서빙 선택: Model-as-a-Service

본 프로젝트에서는 Model-as-a-Service(MaaS) 방식을 선택하였다. MaaS는 모델을 서버 환경에 배포하고 API 형태로 예측 서비스를 제공하는 방식으로, 모델의 관리와 업데이트를 중앙에서 수행할 수 있다는 장점이 있다.

첫째, 지연 시간(latency) 측면에서 본 프로젝트의 Random Forest 모델은 비교적 가벼운 모델이므로 서버 기반 추론 환경에서도 충분히 빠른 응답 속도를 제공할 수 있다. 심장질환 위험도 예측은 실시간 제어 시스템이 아니므로 수 밀리초 수준의 추가 네트워크 지연은 큰 문제가 되지 않는다.

둘째, 개인정보(PHI, Protected Health Information) 측면에서는 환자 데이터가 서버로 전송되므로 적절한 암호화와 접근 제어가 필요하다. 그러나 병원 또는 의료기관 내부 네트워크 환경에서 운영된다고 가정하면 중앙 집중형 데이터 관리 및 감사(audit)가 가능하다는 장점이 있다.

셋째, 업데이트 주기 측면에서 MaaS가 유리하다. 본 프로젝트에서는 데이터 드리프트를 모니터링하고 필요 시 모델을 재학습하도록 설계하였다. 서버 기반 구조에서는 새로운 모델을 한 번만 배포하면 모든 사용자가 즉시 최신 모델을 사용할 수 있으므로 유지보수가 용이하다. 반면 On-Device 방식은 모든 사용자 기기에 개별적으로 모델을 배포해야 하므로 운영 부담이 증가한다.

따라서 본 프로젝트에서는 지속적인 모니터링, 재학습 및 모델 업데이트가 중요한 의료 예측 시스템의 특성을 고려하여 Model-as-a-Service 방식을 선택하였다.

8. 한계, 윤리적 고려 사항, 향후 개선 계획

본 프로젝트는 Cleveland Heart Disease Dataset(303건)을 기반으로 학습되었으며 데이터 규모가 크지 않다는 한계가 있다. 또한 단일 데이터셋을 사용하였기 때문에 다른 병원이나 다른 인구 집단에 대해서도 동일한 성능을 보장하기 어렵다. 실제 의료 환경에서는 환자의 생활 습관, 가족력, 검사 결과 등 더 다양한 정보를 활용할 필요가 있다.

본 프로젝트의 모델은 의료진의 의사결정을 지원하기 위한 보조 도구이며, 최종 진단을 대신해서는 안 된다. 특히 모델이 제시하는 예측 결과가 의료진에게 과도한 신뢰를 유발할 경우 자동화 편향(Automation Bias)이 발생할 수 있다. 예를 들어 모델이 심장질환 위험이 낮다고 예측하더라도 실제로는 환자의 가족력, 생활 습관, 추가 검사 결과, 임상 증상 등 데이터셋에 포함되지 않은 중요한 정보가 존재할 수 있다.

따라서 모델의 예측 결과는 하나의 참고 정보로만 활용되어야 하며, 의료진은 모델 결과에 영향을 받지 않고 독립적으로 환자를 평가할 수 있어야 한다. 또한 실제 환자를 정상으로 분류하는 False Negative는 치료 시기를 놓치게 만들 수 있으므로 특히 신중하게 관리되어야 한다. 의료 AI는 의사의 판단을 대체하는 것이 아니라 보다 안전한 의사결정을 지원하는 역할에 머물러야 한다.

만약 개발 기간이 1주 더 주어진다면 더 많은 의료 데이터를 확보하여 모델의 일반화 성능을 검증할 것이다.

부록. 생성형 AI 도구 활용 내역

본 프로젝트에서는 ChatGPT를 보조 도구로 활용하였다. AI 도구는 함수 및 클래스 이름 제안, 보일러플레이트 코드 작성, unittest 테스트 메서드 초안 생성, inference.py에서 사용할 예시 입력 데이터 생성, 라이브러리 오류 및 실행 환경 관련 디버깅 지원에 활용하였다. 또한 프로젝트 진행 과정에서 발생한 머신러닝, MLOps, MLflow, Docker, 데이터 드리프트 등의 개념적 의문을 해결하기 위한 학습 도구로 사용하였다.

보고서 작성 과정에서는 문장의 표현을 다듬고 논리 구조를 정리하는 데 도움을 받았다

Github 링크 :<https://github.com/KYH20020302/CardioCare.git>